


Gefördert durch:



EFFICIENT RETRIEVAL OF INFORMATION

Local Retrieval Augmented-Generation


Dr. Hanno Müller
Felix Boelter

**Design IT.
Create Knowledge.**

www.hpi.de



Attendence list



Gefördert durch:

LEARNING GOALS

Gefördert durch:



Bundesministerium
für Forschung, Technologie
und Raumfahrt

MOTIVATION

- LLMs are trained on (mostly) public data and have no knowledge of **private data**, e.g.
 - **internal documents** about operational processes
 - **paid documents** such as scientific publications
- LLMs use similar information when relevant information is absent, e.g.
 - legal texts on parking restrictions are used for questions about stopping restrictions
 - popular science texts are used for research questions
- RAG allows **predefined documents** to be used as a basis for answering questions!

Gefördert durch:

CONTENT

- Understand the fundamentals of RAG:
embeddings, vector databases, information retrieval, prompt engineering
- Increase awareness for the requirements for (your own) RAG:
 - document preprocessing, creating vector databases
- Deploy a locally running RAG application on your machine

Gefördert durch:

SCHEDULE

1. General introduction (30 minutes)
2. Demonstration of RAG (30 minutes)
3. Interactive Notebook (30 minutes)
4. Deploy RAG + Break (30 minutes)
5. Customise RAG (30 minutes)
6. Discussion (30 minutes)

Gefördert durch:


FUNDAMENTALS & DEMONSTRATION

Gefördert durch:




Bundesministerium
für Forschung, Technologie
und Raumfahrt

ARCHITECTURE



Gefördert durch:

COMPARISON TO UPLOAD



Common Upload:

- User chooses documents
- Limited number of pages

RAG:

- Relevant information are automatically retrieved
- All available documents are taken into account

Gefördert durch:

DEMO 1.

SENTRA

Gefördert durch:



Bundesministerium
für Forschung, Technologie
und Raumfahrt

- **Background:**

The Research Services of the German Bundestag maintain a vast and ever-growing archive of research reports and studies on a wide range of topics, such as:

- International law
- Budget and finance
- Economy, energy and climate

- **Challenge:**

Answering specialist queries requires extensive research, the extraction of information, and the summarisation of knowledge spread across multiple academic articles

Wissenschaftliche Dienste durchsuchen

Dokumente finden, Fragen beantworten und externe Quellen recherchieren

Dokumente finden

Fragen beantworten

Nach Thema

Ähnliche Dokumente

Externe Quellen

Zeigt alle vorhandenen Dokumente zu einem Thema

CO2-Bepreisung

→ Suchen

Filter

10 Dokumente gefunden

↑↓ Relevanz

Datum



Emissionshandelssystem und Klimaschutz

62%

WD 5 - 3000 - 009/25

Sonstiges

26.05.2025

Wirtschaft, Energie und Umwelt



Einzelfragen zur Berechnung von CO2-Emissionen im Verkehrssektor

43%

WD 8 - 3000 - 013/22

Kurzinformation

21.02.2022

Umwelt, Naturschutz, Reaktorsicherheit, Bildung und Forschung



Spitzensportförderung in ausgewählten europäischen Ländern

27%

WD 10 - 3000 - 013/23

Sachstand

25.07.2023

Kultur, Medien und Sport



Lastenfahrräder Lastenfahrräder

27%

WD 7 - 3000 - 085/22


Sachstand

10.10.2022

Zivil-, Straf- und Verfahrensrecht, Bau und Stadtentwicklung

Wissenschaftliche Dienste durchsuchen

Dokumente finden, Fragen beantworten und externe Quellen recherchieren



Zeigt alle vorhandenen Dokumente zu einem Thema

CO2-Bepreisung

→ Suchen

Filter

10 Dokumente gefunden



Emissionshandelssystem und Klimaschutz

62%

WD 5 - 3000 - 009/25

Sonstiges

26.05.2025

Wirtschaft, Energie und Umwelt



Einzelfragen zur Berechnung von CO2-Emissionen im Verkehrssektor

43%

WD 8 - 3000 - 013/22

Kurzinformation

21.02.2022

Umwelt, Naturschutz, Reaktorsicherheit, Bildung und Forschung



Spitzensportförderung in ausgewählten europäischen Ländern

27%

WD 10 - 3000 - 013/23

Sachstand

25.07.2023

Kultur, Medien und Sport



Lastenfahrräder Lastenfahrräder

27%

WD 7 - 3000 - 085/22

Sachstand


10.10.2022

Zivil-, Straf- und Verfahrensrecht, Bau und Stadtentwicklung

AI Search
results based on semantic
similarity
(instead of keyword matching)

Wissenschaftliche Dienste durchsuchen

Dokumente finden, Fragen beantworten und externe Quellen recherchieren



Nach Thema Ähnliche Dokumente Externe Quellen

Zeigt alle vorhandenen Dokumente zu einem Thema

CO2-Bepreisung

→ Suchen

Filter

10 Dokumente gefunden

Relevanz Datum



Emissionshandelssystem und Klimaschutz

WD 5 - 3000 - 009/25

Sonstiges

26.05.2025

Wirtschaft, Energie und Umwelt

62%



Einzelfragen zur Berechnung von CO2-Emissionen im Verkehrssektor

WD 8 - 3000 - 013/22

Kurzinformation

21.02.2022

Umwelt, Naturschutz, Reaktorsicherheit, Bildung und Forschung

43%



Spitzensportförderung in ausgewählten europäischen Ländern

WD 10 - 3000 - 013/23

Sachstand

25.07.2023

Kultur, Medien und Sport

27%



Lastenfahrräder Lastenfahrräder

WD 7 - 3000 - 085/22

Sachstand

10.10.2022

Zivil-, Straf- und Verfahrensrecht, Bau und Stadtentwicklung

27%

AI Search
results based on semantic
similarity
(instead of keyword matching)

Wissenschaftliche Dienste durchsuchen

Dokumente finden, Fragen beantworten und externe Quellen recherchieren

Dokumente finden

Fragen beantworten

Nach Thema

Ähnliche Dokumente

Externe Quellen

Zeigt alle vorhandenen Dokumente zu einem Thema

CO2-Bepreisung

→ Suchen

Filter

10 Dokumente gefunden

↑↓ Relevanz

Datum



Emissionshandelssystem und Klimaschutz

62%

WD 5 - 3000 - 009/25

Sonstiges

26.05.2025

Wirtschaft, Energie und Umwelt



Einzelfragen zur Berechnung von CO2-Emissionen im Verkehrssektor

43%

WD 8 - 3000 - 013/22

Kurzinformation

21.02.2022

Umwelt, Naturschutz, Reaktorsicherheit, Bildung und Forschung



Spitzensportförderung in ausgewählten europäischen Ländern

27%

WD 10 - 3000 - 013/23

Sachstand

25.07.2023

Kultur, Medien und Sport



Lastenfahrräder Lastenfahrräder

27%

WD 7 - 3000 - 085/22

Sachstand

10.10.2022

Zivil-, Straf- und Verfahrensrecht, Bau und Stadtentwicklung

CO2-Bepreisung

→ Suchen

Filter

Zeitraum:

Von



–

Bis



Alle Typen



Alle Referate



Wissenschaftliche Dienste durchsuchen

Dokumente finden, Fragen beantworten und externe Quellen recherchieren

Dokumente finden

Fragen beantworten

Nach Thema

Ähnliche Dokumente

Externe Quellen

Findet ähnliche Dokumente zu einem bestehenden Dokument

WD 5 - 3000 - 009/25

→ Suchen

10 Dokumente gefunden — ähnlich zu WD 5 - 3000 - 009/25

↑↓ Relevanz

Datum



Einzelfragen zur Berechnung von CO2-Emissionen im Verkehrssektor

50%

WD 8 - 3000 - 013/22

Kurzinformation

21.02.2022

Umwelt, Naturschutz, Reaktorsicherheit, Bildung und Forschung



Umweltrechtliche Aspekte der Sedimentverbringung in

41%

WD 8 - 3000 - 011/22

Dokumentation

03.03.2022

Umwelt, Naturschutz, Reaktorsicherheit, Bildung und Forschung



Regulations of state legal representation in international courts, arbitration, EU courts

40%

WD 2 - 3000 - 027/25

Sonstiges

28.07.2025

Auswärtiges, Völkerrecht, Wirtschaftliche Zusammenarbeit und Entwicklung, Verteidigung, Menschenrechte und humanitäre Hilfe



Die Lootbox im deutschen Recht und im europäischen Vergleich

39%

WD 1 - 3000 - 019/24

Sachstand

17.10.2024

Geschichte, Zeitgeschichte und Politik

Wissenschaftliche Dienste durchsuchen

Dokumente finden, Fragen beantworten und externe Quellen recherchieren

Dokumente finden

Fragen beantworten

Nach Thema

Ähnliche Dokumente

Externe Quellen

Findet ähnliche Dokumente zu einem bestehenden Dokument

WD 5 - 3000 - 009/25

→ Suchen

10 Dokumente gefunden — ähnlich zu WD 5 - 3000 - 009/25

↑↓ Relevanz

Datum



Einzelfragen zur Berechnung von CO2-Emissionen im Verkehrssektor

50%

WD 8 - 3000 - 013/22

Kurzinformation

21.02.2022

Umwelt, Naturschutz, Reaktorsicherheit, Bildung und Forschung



Umweltrechtliche Aspekte der Sedimentverbringung in

41%

WD 8 - 3000 - 011/22

Dokumentation

03.03.2022

Umwelt, Naturschutz, Reaktorsicherheit, Bildung und Forschung



Regulations of state legal representation in international courts, arbitration, EU courts

40%

WD 2 - 3000 - 027/25

Sonstiges

28.07.2025

Auswärtiges, Völkerrecht, Wirtschaftliche Zusammenarbeit und Entwicklung, Verteidigung, Menschenrechte und humanitäre Hilfe



Die Lootbox im deutschen Recht und im europäischen Vergleich

39%

WD 1 - 3000 - 019/24

Sachstand

17.10.2024

Geschichte, Zeitgeschichte und Politik

AI Search
results based on semantic
similarity
(instead of keyword matching)

Wissenschaftliche Dienste durchsuchen

Dokumente finden, Fragen beantworten und externe Quellen recherchieren

 Dokumente finden

 Fragen beantworten

 Nach Thema

 Ähnliche Dokumente

 Externe Quellen

Zeigt externe Quellen und Datenportale aus unseren Dokumenten

CO2-Bepreisung

→ Suchen

 Filter

57 externe Quellen in den Dokumenten referenziert



<https://www.wirtschaftsdienst.eu/inhalt/jahr/2025/heft/1/beitrag/zertifikatehandel-ist-das-am-besten-geeignete-instrument-der-klimapolitik.html>

2 Vgl. im Folgenden Wein, T. (2025), Zertifikatehandel ist das am besten geeignete Instrument der Klimapolitik, Wirtschaftsdienst, 105. Jahrgang, 2025, Heft 1, S. 64-68, <https://www.wirtschaftsdienst....>

 ZITIERT IN: **WD 5 - 3000 - 009/25**



<https://doi.org/10.1038/s44168-024-00196-0>

3 Callaghan, M., Banisch, L., Doebling-Hildebrandt, N. et al. (2025), Machine learning map of climate policy literature reveals disparities between scientific attention, policy density, and emission...

 ZITIERT IN: **WD 5 - 3000 - 009/25**



<https://carbonpricingdashboard.worldbank.org/>

Wissenschaftliche Dienste durchsuchen

Dokumente finden, Fragen beantworten und externe Quellen recherchieren

Dokumente finden

Fragen beantworten

Fachfrage

Themenüberblick

Beantwortet eine konkrete Frage mit Quellenbezug

Wann tritt ETS 2 in Kraft?



→ Suchen

Filter

Laut dem Kontext tritt ETS2 (das neue Emissionshandelssystem) im Jahr 2027 in Kraft [1]. Es wird für Gebäude, Straßenverkehr und andere Brennstoffe eingeführt. Bereits 2025 beginnt die Überwachung und Berichterstattung der Emissionen [1].

> </> Systemanweisung anzeigen

QUELLEN (3)

1 Emissionshandelssystem und Klimaschutz

WD 5 - 3000 - 009/25 26.05.2025

2 Die Lootbox im deutschen Recht und im europäischen Vergleich

WD 1 - 3000 - 019/24 17.10.2024

3 Zur Ersteinschätzung in Notaufnahmen von Krankenhäusern

WD 9 - 3000 - 068/23 23.11.2023

Wissenschaftliche Dienste durchsuchen

Dokumente finden, Fragen beantworten und externe Quellen recherchieren

Dokumente finden

Fragen beantworten

Fachfrage

Themenüberblick

Beantwortet eine konkrete Frage mit Quellenbezug

Wann tritt ETS 2 in Kraft?



→ Suchen

Filter

Laut dem Kontext tritt ETS2 (das neue Emissionshandelssystem) im Jahr 2027 in Kraft [1]. Es wird für Gebäude, Straßenverkehr und andere Brennstoffe eingeführt. Bereits 2025 beginnt die Überwachung und Berichterstattung der Emissionen [1].

> </> Systemanweisung anzeigen

QUELLEN (3)

1 Emissionshandelssystem und Klimaschutz

WD 5 - 3000 - 009/25 26.05.2025

2 Die Lootbox im deutschen Recht und im europäischen Vergleich

WD 1 - 3000 - 019/24 17.10.2024

3 Zur Ersteinschätzung in Notaufnahmen von Krankenhäusern

WD 9 - 3000 - 068/23 23.11.2023

AI Summary
Immediate response to questions

Wissenschaftliche Dienste durchsuchen

Dokumente finden, Fragen beantworten und externe Quellen recherchieren

Dokumente finden

Fragen beantworten

Fachfrage

Themenüberblick

Beantwortet eine konkrete Frage mit Quellenbezug

Wann tritt ETS 2 in Kraft?



→ Suchen

Filter

Laut dem Kontext tritt ETS2 (das neue Emissionshandelssystem) im Jahr 2027 in Kraft [1]. Es wird für Gebäude, Straßenverkehr und andere Brennstoffe eingeführt. Bereits 2025 beginnt die Überwachung und Berichterstattung der Emissionen [1].

> </> Systemanweisung anzeigen

QUELLEN (3)

1 Emissionshandelssystem und Klimaschutz

WD 5 - 3000 - 009/25 26.05.2025

2 Die Lootbox im deutschen Recht und im europäischen Vergleich

WD 1 - 3000 - 019/24 17.10.2024

3 Zur Ersteinschätzung in Notaufnahmen von Krankenhäusern

WD 9 - 3000 - 068/23 23.11.2023

Sources for transparency

Wissenschaftliche Dienste durchsuchen

Dokumente finden, Fragen beantworten und externe Quellen recherchieren

 Dokumente finden

 Fragen beantworten

 Fachfrage

 Themenüberblick

Erstellt eine strukturierte Übersicht zum aktuellen Wissensstand

CO2-Bepreisung



→ Suchen

 Filter

Zusammenfassung des aktuellen Stands

Die CO2-Bepreisung ist ein zentrales Instrument der Klimapolitik in Deutschland und der EU, um den Ausstoß von Treibhausgasen zu reduzieren. Durch die Einführung eines Marktes für Emissionsrechte soll ein Preis für Kohlenstoffemissionen festgelegt werden, der Unternehmen und Verbraucher dazu anregt, Emissionen zu vermeiden und in klimafreundliche Technologien zu investieren. Die EU hat Anfang 2023 eine umfassende Reform des Emissionshandels beschlossen, die unter anderem die Einführung eines neuen Emissionshandelssystems (ETS2) für Gebäude, Straßenverkehr und andere Brennstoffe vorsieht.

Hintergrund und Ziele des Emissionshandels

Der Europäische Emissionshandel (EU-ETS) wurde 2005 als zentrales Klimaschutzinstrument eingeführt und umfasst wichtige Sektoren wie die Energieerzeugung, energieintensive Industrien und den Luftverkehr. Ziel des EU-ETS ist es, bis 2030 eine Nettoemissionsreduktion von mindestens 55 Prozent (gegenüber 1990) zu erreichen. Der Emissionshandel ermöglicht Unternehmen Flexibilität, indem sie entweder in Klimaschutz investieren oder Emissionsrechte kaufen können.

Preisbildung und -entwicklung

Die Preisbildung im CO2-Zertifikatehandel erfolgt durch das Verhältnis von Angebot und Nachfrage auf dem Markt für

Preisbildung und -entwicklung

Die Preisbildung im CO₂-Zertifikatehandel erfolgt durch das Verhältnis von Angebot und Nachfrage auf dem Markt für Emissionsberechtigungen. Der Marktpreis für diese Berechtigungen wird durch Auktionen und den Handel zwischen den Unternehmen bestimmt. Steigende CO₂-Preise sind eine Möglichkeit, um Emissionen effektiv zu senken und Klimaziele zu erreichen. Höhere Preise für CO₂-intensive Produkte und Energie spiegeln die tatsächlichen Umweltkosten wider und setzen Anreize für Unternehmen und Verbraucher, emissionsärmere Alternativen zu wählen.

Herausforderungen und Handlungsoptionen

Die Entwicklung der CO₂-Preise im ETS2 ist mit erheblichen Unsicherheiten verbunden. Um soziale Härten und Preissprünge abzumildern, sollen eine Reihe von Maßnahmen sicherstellen, dass Klimaschutz ökonomisch und sozial ausgewogen bleibt. Dazu gehören die Einführung eines Klimageldes, das antragslos und automatisch ausgezahlt werden soll, sowie die Verwendung von Einnahmen aus der CO₂-Bepreisung für die Finanzierung von umweltfreundlichen Investitionen und die Unterstützung von vulnerablen Haushalten.

Soziale Auswirkungen und Entlastungsmaßnahmen

Die CO₂-Bepreisung kann zu sozialen Härten in Bevölkerungsgruppen führen, die durch strukturelle Faktoren einen sehr hohen Verbrauch fossiler Energien aufweisen. Um diese Härten zu mildern, sieht die Bundesregierung ein Klimageld vor, das antragslos und automatisch ausgezahlt werden soll. Parallel dazu hat die EU den Social Climate Fund (SCF) ins Leben gerufen, um vulnerable Gruppen beim Übergang zur Klimaneutralität zu unterstützen.

Fazit

Die CO₂-Bepreisung ist ein wichtiges Instrument der Klimapolitik, um den Ausstoß von Treibhausgasen zu reduzieren. Durch die Einführung eines Marktes für Emissionsrechte soll ein Preis für Kohlenstoffemissionen festgelegt werden, der Unternehmen und Verbraucher dazu anregt, Emissionen zu vermeiden und in klimafreundliche Technologien zu investieren. Um soziale Härten und Preissprünge abzumildern, sind jedoch weitere Maßnahmen erforderlich, wie die Einführung eines Klimageldes und die Verwendung von Einnahmen aus der CO₂-Bepreisung für die Finanzierung von umweltfreundlichen Investitionen und die Unterstützung von vulnerablen Haushalten.

> </> Systemanweisung anzeigen

📖 QUELLEN (1)

- 1 Emissionshandelssystem und Klimaschutz

WD 5 - 3000 - 009/25 📅 26.05.2025

DEMO 2.

IT BASELINE PROTECTION

Gefördert durch:



Bundesministerium
für Forschung, Technologie
und Raumfahrt



No threads found

[Readme](#)



[Einstellungen](#)



H



Gefördert durch:



Bundesministerium
für Forschung, Technologie
und Raumfahrt

Type your message here...

Nutze `"/export all` um alle Chats zu exportieren.



Was ist der Unterschied zwischen Prozess- und Systembausteinen?



Welche Schritte umfasst die Basis-Absicherung nach BSI-Standard 200-2?



Wie müssen Passwörter bei der Authentisierung am Webserver gesicher...

[Impressum](#) · [Datenschutz](#) · [Nutzungsbedingungen](#)

EXERCISE

Gefördert durch:



Bundesministerium
für Forschung, Technologie
und Raumfahrt

GITHUB REPOSITORY

<https://github.com/aihpi/workshop-ragV2/>

GEFÖRDERT VOM



Bundesministerium
für Bildung
und Forschung

EXERCISE

Option A (easy):

Go to <https://raglab.aisc.hpi.de/> and log in with your GitHub account. Upload your own data, ask questions about it, change the prompt. How does it work?

Option B (medium):

Go to <https://github.com/aihpi/workshop-ragV2/> and follow the instruction in langflow/README.md in order to install langflow. Complete the incompleeted flows. Compare running flows to Option A.

Option C (difficult):

Go to <https://github.com/aihpi/workshop-ragV2/> and follow the instructions in README.md in order to install you own local RAG application (Ollama backend, react frontend).

Gefördert durch:

DISCUSSION

Gefördert durch:



Bundesministerium
für Forschung, Technologie
und Raumfahrt



Four AI Service Centres in Germany



Gefördert durch:



Bundesministerium
für Forschung, Technologie
und Raumfahrt



KI-Servicezentren

Goal:

Reduce barriers to the implementation
of AI applications in society and the
economy



Gefördert durch:

- AI methods research
- AI operations research

PubMedCLIP: How Much Does CLIP Benefit Visual Question Answering in the Medical Domain?

Sedigheh Eslami, Christoph Meinel, Gerard de Melo

Hasso Plattner Institute / University of Potsdam

{sedigheh.eslami, christoph.meinel, gerard.demelo}@hpi.de

Abstract

Contrastive Language-Image Pre-training (CLIP) has shown remarkable success in learning with cross-modal supervision from extensive amounts of image-text pairs collected online. Thus far, the effectiveness of CLIP has been investigated primarily in general-domain multimodal problems. In this work, we evaluate the effectiveness of CLIP for the task of Medical Visual Question Answering (MedVQA). We present PubMedCLIP, a fine-tuned version of CLIP for the medical domain based on PubMed articles. Our experiments conducted on two MedVQA benchmark datasets illustrate that PubMedCLIP achieves superior results improving the overall accuracy up to 3% in comparison to the state-of-the-art Model-Agnostic Meta-Learning (MAML) networks pre-trained only on visual data. The PubMedCLIP model with different back-ends, the source code for pre-training them and reproducing our MedVQA pipeline is publicly available at <https://github.com/samhisl/PubMedCLIP>.

1 Introduction

Medical visual question answering (MedVQA) seeks answers to natural language questions about a given medical image. The development of MedVQA has considerable potential to benefit health care systems, as it may aid clinicians in interpreting medical images and obtaining more accurate diagnoses by consulting a second opinion. Thus, it has become a very active area of research, with competitive benchmarks and yearly competitions (Abacha et al., 2021). Yet, visual question answering in the medical domain in particular remains non-trivial as we suffer from a general lack of large balanced training data, in part due to privacy concerns. To solve the multimodal task of MedVQA, a system must understand both medical images and textual questions and infer the associations between them sufficiently well to produce a correct answer (An

Findings of the Association for Computational Linguistics
May 2-6, 2023 ©2023 Association for Computational Linguistics

Exploring Paracrawl for Document-level Neural Machine Translation

Yusser Al Ghussin^{1,2}, Jingyi Zhang³ and Josef van Genabith^{1,2}

¹German Research Center for Artificial Intelligence (DFKI),

Saarland Informatics Campus, Saarbrücken, Germany

²Department of Language Science and Technology, Saarland University, Germany

³Hasso-Plattner-Institut (HPI), Potsdam, Germany

yusser.al_ghussin@Josef.Van_Genabith@dfki.de, Jingyi.Zhang@hpi.de

Abstract

Document-level neural machine translation (NMT) has outperformed sentence-level NMT on a number of datasets. However, document-level NMT is still not widely adopted in real-world translation systems mainly due to the lack of large-scale general-domain training data for document-level NMT. We examine the effectiveness of using Paracrawl for learning document-level translation. Paracrawl is a large-scale parallel corpus crawled from the Internet and contains data from various domains. The official Paracrawl corpus was released as parallel sentences (extracted from parallel webpages) and therefore previous works only used Paracrawl for learning sentence-level translation. In this work, we extract parallel paragraphs from Paracrawl parallel webpages using automatic sentence alignments and we use the extracted parallel paragraphs as parallel documents for training document-level translation models. We show that document-level NMT models trained with only parallel paragraphs from Paracrawl can be used to translate real documents from TED, News and Europarl, outperforming sentence-level NMT models. We also perform a targeted pronoun evaluation and show that document-level models trained with Paracrawl data can help context-aware pronoun translation. We release our data and code here¹.

1 Introduction

The Transformer translation model (Vaswani et al., 2017), which performs sentence-level translation based on attention networks, has achieved great success and significantly improved the state-of-the-art in machine translation. Compared to sentence-level translation, document-level translation (Xu et al., 2021; Bao et al., 2021; Jauregi Urraue et al., 2020; Ma et al., 2020; Maruf et al., 2019; Tu et al., 2018; Maruf and Haffari, 2018) performs translation at document-level and can potentially fur-

¹<https://github.com/Yusser96/Exploring-Paracrawl-for-Docment-level-Neural-Machine-Translation>

Proceedings of the 17th Conference of the European Chapter of the Association for Computational Linguistics
May 2-6, 2023 ©2023 Association for Computational Linguistics

Efficient Parallelization Layouts for Large-Scale Distributed Model Training

Johannes Hagemann
Aleph Alpha / Hasso Plattner Institute
johannes.hagemann@student.hpi.de

Samuel Weinbach
Aleph Alpha
samuel.weinbach@aleph-alpha.com

Konstantin Dobler
Hasso Plattner Institute
konstantin.dobler@hpi.de

Maximilian Schall
Hasso Plattner Institute
maximilian.schall@hpi.de

Gerard de Melo
Hasso Plattner Institute
gerard.demelo@hpi.de

Abstract

Efficiently training large language models requires parallelizing across hundreds of hardware accelerators and invoking various compute and memory optimizations. When combined, many of these strategies have complex interactions regarding the final training efficiency. Prior work tackling this problem did not have access to the latest set of optimizations, such as FLASHATTENTION or sequence parallelism. In this work, we conduct a comprehensive ablation study of possible training configurations for large language models. We distill this large study into several key recommendations for the most efficient training. For instance, we find that using a micro-batch size of 1 usually enables the most efficient training layouts. Larger micro-batch sizes necessitate activation checkpointing or higher degrees of model parallelism and also lead to larger pipeline bubbles. Our most efficient configurations enable us to achieve state-of-the-art training efficiency results over a range of model sizes, most notably a Model FLOPs utilization of 70.5% when training a LLaMA 13B model.

1 Introduction

The number of parameters and computational resources spent on training deep neural networks is growing rapidly [1, 3, 14]. The largest models consisting of hundreds of billions of parameters do not even fit onto a single hardware accelerator. Thus, training these models requires various ways of reducing the memory requirements, such as ZeRO [16], activation checkpointing [2], and 3D-parallel (data, tensor, and pipeline parallel) training [13]. 3D parallelism, in particular, has been demonstrated to be effective for the training of Transformer-based large language models (LLMs) with hundreds of billions of parameters [13].

However, training these models efficiently with 3D parallelism requires significant domain expertise and extensive manual effort to determine the ideal configurations. These configurations not only need to combine data, model, and pipeline parallelism most efficiently, but also consider complex interactions with other memory and compute optimizations. FLASHATTENTION [5] in particular has had a notable impact since its release, enabling us to train models at previously impossible degrees of training efficiency. In light of these developments, we conduct a systematic study via a large-scale training efficiency sweep of these interactions. We consider up to 256 GPUs and LLaMA models with up to 65 billion parameters.

Workshop on Advancing Neural Network Training at 37th Conference on Neural Information Processing Systems (WANT@NeurIPS 2023).

Gefördert durch:



Bundesministerium
für Forschung, Technologie
und Raumfahrt



Zugangsanfrage
aisc.hpi.de



- **Free access**
- No production operation
 - Data should be **anonymised** or **synthesised**
 - No **hosting** of products
- **Reporting & publication** by users
- **Old rights** remain with users
- **New rights** remain with users
 - Granting of rights of use for research and teaching

Infrastructure

Training

- 64 NVIDIA H100 GPU

Inference

- 40 NVIDIA A30 GPU

ARM Server

- Ampere Altra Max M128-30 CPU
- 2 x NVIDIA L40 GPUs

GPU Server

- AMD Epyc CPU
- 8 x NVIDIA L40S GPU

Edge

- ARMv8 CPU
- NVIDIA Jetson AGX Module

Neuromorph

- 288 SpiNNaker2 Chips

Storage

- 1.5 PB NVMe

Network

- 400 Gb/s Infiniband
- 200 Gb/s Ethernet



Newsletter

Education

Talks



tele-task.de/series/1463

- Guest talks about research and innovation




Workshops



aimaker.community

- Practical topics
- Example topics: Speech2summary, Docker for ML, semantic search



MOOCs



open.hpi.de/channels/ai-service-center

- ChatGPT: What does generative AI mean for our society?
- Profitable AI
- Understanding and avoiding AI biases



Gefördert durch:



Bundesministerium
für Forschung, Technologie
und Raumfahrt



Sprechstunde buchen

Consulting

AI consultation hours

- Answering questions:
 - about AI infrastructure
 - about AI models & frameworks
 - about AI use cases

AI pilot projects

- Co-development of a prototype
- Application every three months
- Selection criteria, e.g. AI maturity, public benefit
- Publication of results

Cooperation

- Jointly organized network meetings



Previous AI pilot projects

- Generation of math problems
- Generation of easy language
- Generation of upcycling suggestions
- Reduction of food waste
- Dating by handwriting



Jetzt bewerben!

Kontrast: Normal Kontrast: Invertiert Kontrast: Graustufen

KI-Prototyp Leichte-Sprache-Assistent (LeISA)

Vereinfachte Texte mit LLMs! - [Zum Projekt auf GitHub](#)

Originaltext

Das KI-Servicezentrum Berlin-Brandenburg ist ein Projekt vom Hasso-Plattner-Institut. Unser Ziel ist, den Einsatz von Künstlicher Intelligenz in Wirtschaft und Gesellschaft zu fördern.

Unser Schwerpunkt liegt auf der Unterstützung von Start-ups, kleinen und mittelständischen Unternehmen, öffentlichen Einrichtungen, Studierenden und der Forschung. Wir bieten kostenfrei die notwendigen Beratungsleistungen, Bildungsangebote und Infrastruktur, um KI-Anwendungen zu entwickeln, zu betreiben und erfolgreich einzusetzen.

Leichte Sprache

Unser Ziel

Wir möchten, dass viele Menschen und Unternehmen KI-Anwendungen nutzen können.

Wer kann sich an uns wenden?

Studierende
Kleine und mittelständische Unternehmen
Start-ups
Öffentliche Einrichtungen

Was bieten wir an?

- Kostenlose Beratung
- Bildungsangebote
- Infrastruktur, um KI-Anwendungen zu entwickeln

Beispiele für unsere Arbeit

Ein Unternehmen möchte eine App entwickeln, die Menschen bei der Einkaufsliste hilft.
Eine Forschungsgruppe möchte ein System bauen, das Menschen bei der Krankenvorsorge unterstützt.
Wir helfen ihnen gerne!

Hinweis zur Übersetzung: Dieser Text wurde mit einer KI erstellt.

Bitte verarbeiten Sie keine personenbezogenen Daten mit dem Tool. Falls der Prototyp einmal nicht verfügbar sein sollte, kontaktieren Sie uns gern, wir kümmern uns darum.

Vereinfachen! Löschen

Der KI-Prototyp LeISA ist ein gemeinsames Projekt der Digitalagentur Brandenburg GmbH und des KI-Servicezentrums (KSZ) vom Hasso-Plattner-Institut.
*Fördert durch das Ministerium der Justiz und für Digitalisierung des Landes Brandenburg
*Fördert vom Bundesministerium für Bildung und Forschung.

github.com/aihpi/leichte-sprache

Speech processing



<https://tts.aisc.hpi.de/>
user: event
pw: aisc@hpi2022!

Prototypes

Voice Dubbing Demonstrator

Select Reference Audio

Choose input method:

- ☒ Record Audio
- ☐ Use Predefined Audio

Click the button below to start recording your audio.



 Processing →

←  Scenarios

Voice Dubbing Demonstrator

At an Event

Cloned Voice (3/3)

That's exactly why we're here today, discussing the importance of making sure AI systems are trustworthy and responsible.



Gefördert durch:



Bundesministerium
für Forschung, Technologie
und Raumfahrt

kisz@hpi.de

hpi.de/kisz

Your opinion is
relevant!



QR code to feedback form



Gefördert durch: