

Gefördert durch:




AI Service Centre Berlin-Brandenburg

Felix Boelter & Dr. Hanno Müller

**Design IT.
Create Knowledge.**

www.hpi.de




RETRIEVAL-AUGMENTED GENERATION

Gefördert durch:



Bundesministerium
für Forschung, Technologie
und Raumfahrt

INGESTION & RETRIEVAL



Gefördert durch:

WHY CHUNKING?

1. Embeddings Models have a token limit

- Usually 512—8,192 tokens

2. LLMs have a context window

- Even if 40-page book fits into one embedding, the embedding does not fit into context window

3. Retrieval should focus on relevant information

- 40-page book contains relevant information and much more irrelevant information


→ Chunking is rather **defining the unit of meaning** than 'just splitting'

Gefördert durch:

THE CHUNKING CONTINUUM

One sentence per chunk

- sharp retrieval
- no surrounding context



One document per chunk

- meaningless retrieval
- all surrounding context

Sweet spot:
'self contained answers to plausible questions'

Gefördert durch:

LESSONS FROM EXPERIENCE

1. Domain matters more than algorithm

- A chunking strategy that wins on HPI website may lose on Python source code
- Performance of same strategy on same data may vary depending on users' questions

2. Embedding and chunking choice interact

- An embedding model with 512-token limit requires other chunks than an embedding model with 8k-token limit

Gefördert durch:

HANDS-ON I - CHUNKING

Gefördert durch:



Bundesministerium
für Forschung, Technologie
und Raumfahrt

EMBEDDING MODELS

1. Embeddings models are more important for retrieval with chunking
 - **Bad** chunking strategy + **bad** embedding model = bad results
 - **Bad** chunking strategy + **good** embedding model = reasonable results
 - **Good** chunking strategy + **good** embedding model = optimal results
2. Embedding is a function that maps input into vector of fixed dimension d :

$$f : \mathcal{X} \rightarrow \mathbb{R}^d$$

The function is engineered (through training) so that semantically similar inputs map to nearby vectors

Gefördert durch:

MATRYOSHKA CONCEPT

1. Any prefix of the embedding vector is an embedding vector by itself, e.g.,
 - 4,096-d vector can be reduced to first 512-d vector
2. How it works
 - The model is trained with **sum of losses** at multiple nested dimensions, e.g., losses computed at $d=128$, $d=256$, ..., $d=4096$, all summed and backpropagated jointly

→ Forces optimiser to pack most useful information into earliest dimensions

3. Why?

- Faster inference with almost same quality at lower cost
- e.g., 512-d instead of 4096-d vectors yield 8x smaller storage, 8x faster search, and 8x cheaper vector DB costs



Gefördert durch:



Bundesministerium
für Forschung, Technologie
und Raumfahrt

AI SERVICE CENTRE

Gefördert durch:




Bundesministerium
für Forschung, Technologie
und Raumfahrt

FOUR AI SERVICE CENTRES



<https://hpi.de/ki-servicezentrum/>



Gefördert durch:



Bundesministerium
für Forschung, Technologie
und Raumfahrt



KI-Servicezentren

Objective:
**Barriers to implementation of
AI applications in society and
industry reducing**

OVERVIEW



Gefördert durch:



Bundesministerium
für Forschung, Technologie
und Raumfahrt

RESEARCH

- AI Methods Research
- AI Operations Research

PubMedCLIP: How Much Does CLIP Benefit Visual Question Answering in the Medical Domain?

Sedigheh Eslami, Christoph Meinel, Gerard de Melo

Hasso Plattner Institu

{sedigheh.eslami, christoph

Abstract

Contrastive Language-Image Pre-training (CLIP) has shown remarkable success in learning with cross-modal supervision from extensive amounts of image-text pairs collected online. Thus far, the effectiveness of CLIP has been investigated primarily in general-domain multimodal problems. In this work, we evaluate the effectiveness of CLIP for the task of Medical Visual Question Answering (MedVQA). We present PubMedCLIP, a fine-tuned version of CLIP for the medical domain based on PubMed articles. Our experiments conducted on two MedVQA benchmark datasets illustrate that PubMedCLIP achieves superior results improving the overall accuracy up to 3% in comparison to the state-of-the-art Model-Agnostic Meta-Learning (MAML) networks pre-trained only on visual data. The PubMedCLIP model with different back-ends, the source code for pre-training them and reproducing our MedVQA pipeline is publicly available at <https://github.com/sarahESL/PubMedCLIP>.

1 Introduction

Medical visual question answering (MedVQA) seeks answers to natural language questions about a given medical image. The development of MedVQA has considerable potential to benefit health care systems, as it may aid clinicians in interpreting medical images and obtaining more accurate diagnoses by consulting a second opinion. Thus, it has become a very active area of research, with competitive benchmarks and yearly competitions (Abacha et al., 2021). Yet, visual question answering in the medical domain in particular remains non-trivial as we suffer from a general lack of large balanced training data, in part due to privacy concerns. To solve the multimodal task of MedVQA, a system must understand both medical images and textual questions and infer the associations between them sufficiently well to produce a correct answer (An

Findings of the Association for Computational Linguistics
May 2-6, 2023 ©2023 Association for Computational Linguistics

Exploring Paracrawl for Document-level Neural Machine Translation

Yusser Al Ghussin^{1,2}, Jingyi Zhang³ and Josef van Genabith^{1,2}

¹German Research Center for Artificial Intelligence (DFKI),

Saarland Informatics Campus, Saarbrücken, Germany

²Department of Language Science and Technology, Saarland University, Germany

³Hasso Plattner-Institut (HPI), Potsdam, Germany

yusser.al_ghussin@Josef.Van_Genabith@dfki.de, Jingyi.Zhang@hpi.de

Abstract

Document-level neural machine translation (NMT) has outperformed sentence-level NMT on a number of datasets. However, document-level NMT is still not widely adopted in real-world translation systems mainly due to the lack of large-scale general-domain training data for document-level NMT. We examine the effectiveness of using Paracrawl for learning document-level translation. Paracrawl is a large-scale parallel corpus crawled from the Internet and contains data from various domains. The official Paracrawl corpus was released as parallel sentences (extracted from parallel webpages) and therefore previous works only used Paracrawl for learning sentence-level translation. In this work, we extract parallel paragraphs from Paracrawl parallel webpages using automatic sentence alignments and we use the extracted parallel paragraphs as parallel documents for training document-level translation models. We show that document-level NMT models trained with only parallel paragraphs from Paracrawl can be used to translate real documents from TED, News and Europarl, outperforming sentence-level NMT models. We also perform a targeted pronoun evaluation and show that document-level models trained with Paracrawl data can help context-aware pronoun translation. We release our data and code here¹.

1 Introduction

The Transformer translation model (Vaswani et al., 2017), which performs sentence-level translation based on attention networks, has achieved great success and significantly improved the state-of-the-art in machine translation. Compared to sentence-level translation, document-level translation (Xu et al., 2021; Bao et al., 2021; Jauregi Unanue et al., 2020; Ma et al., 2020; Maruf et al., 2019; Tu et al., 2018; Maruf and Haffari, 2018) performs translation at document-level and can potentially fur

¹<https://github.com/Yusser96/Exploring-Paracrawl-for-Documents-level-Neural-Machine-Translation>

Proceedings of the 17th Conference of the European Chapter of the Association for Computational Linguistics
May 2-6, 2023 ©2023 Association for Computational Linguistics

Efficient Parallelization Layouts for Large-Scale Distributed Model Training

Johannes Hagemann
Aleph Alpha / Hasso Plattner Institute
johannes.hagemann@student.hpi.de

Samuel Weinbach
Aleph Alpha
samuel.weinbach@aleph-alpha.com

Konstantin Dobler
Hasso Plattner Institute
konstantin.dobler@hpi.de

Maximilian Schall
Hasso Plattner Institute
maximilian.schall@hpi.de

Gerard de Melo
Hasso Plattner Institute
gerard.demelo@hpi.de

Abstract

Efficiently training large language models requires parallelizing across hundreds of hardware accelerators and invoking various compute and memory optimizations. When combined, many of these strategies have complex interactions regarding the final training efficiency. Prior work tackling this problem did not have access to the latest set of optimizations, such as FLASHATTENTION or sequence parallelism. In this work, we conduct a comprehensive ablation study of possible training configurations for large language models. We distill this large study into several key recommendations for the most efficient training. For instance, we find that using a micro-batch size of 1 usually enables the most efficient training layouts. Larger micro-batch sizes necessitate activation checkpointing or higher degrees of model parallelism and also lead to larger pipeline bubbles. Our most efficient configurations enable us to achieve state-of-the-art training efficiency results over a range of model sizes, most notably a Model FLOPs utilization of 70.5% when training a LLaMA 13B model.

1 Introduction

The number of parameters and computational resources spent on training deep neural networks is growing rapidly [1, 3, 14]. The largest models consisting of hundreds of billions of parameters do not even fit onto a single hardware accelerator. Thus, training these models requires various ways of reducing the memory requirements, such as ZeRO [16], activation checkpointing [2], and 3D-parallel (data, tensor, and pipeline parallel) training [13]. 3D parallelism, in particular, has been demonstrated to be effective for the training of Transformer-based large language models (LLMs) with hundreds of billions of parameters [13].

However, training these models efficiently with 3D parallelism requires significant domain expertise and extensive manual effort to determine the ideal configurations. These configurations not only need to combine data, model, and pipeline parallelism most efficiently, but also consider complex interactions with other memory and compute optimizations. FLASHATTENTION [5] in particular has had a notable impact since its release, enabling us to train models at previously impossible degrees of training efficiency. In light of these developments, we conduct a systematic study via a large-scale training efficiency sweep of these interactions. We consider up to 256 GPUs and LLaMA models with up to 65 billion parameters.

Workshop on Advancing Neural Network Training at 37th Conference on Neural Information Processing Systems (WANT@NeurIPS 2023).

Gefördert durch:



Bundesministerium
für Forschung, Technologie
und Raumfahrt

KI Service
Zentrum
by Hasso-Plattner-Institut



EDUCATION



Newsletter

Talks



tele-task.de/series/1463

- Guest talks on research and innovation




Workshops



aimaker.community

- Practical topics
- Example topics: Speech2summary, Docker for ML, semantic search



MOOCs



open.hpi.de/channels/ai-service-center

- ChatGPT: What does generative AI mean for our society?
- Profitable AI
- Understanding and avoiding AI biases



Gefördert durch:



Bundesministerium
für Forschung, Technologie
und Raumfahrt

INFRASTRUCTURE



aisc.hpi.de



- Access **free of charge**
- No production operation
 - Data should be **anonymised** or **synthesised**
 - No **hosting of products**
- **Reporting & publication** by users
- **Existing rights** remain with users
- **New rights** remain with users
 - Granting of rights for research and teaching

Training

- 64 NVIDIA H100 GPU

Inference

- 40 NVIDIA A30 GPU

ARM Server

- Ampere Altra Max M128-30 CPU
- 2 x NVIDIA L40 GPUs

GPU Server

- AMD Epyc CPU
- 8 x NVIDIA L40S GPU

Edge

- ARMv8 CPU
- NVIDIA Jetson AGX Module

Neuromorph

- 288 SpiNNaker

Storage

- 1.5 PB NVRAM

Network

- 400 Gb/s Infiniband
- 200 Gb/s Ethernet

Gefördert durch:



Bundesministerium
für Forschung, Technologie
und Raumfahrt

ADVISORY



Consultation

AI Consultation


- AI Infrastructure
- AI Models & Frameworks
- AI Use Cases

AI Pilot Projects

- Co-development of a prototype
- Applications every three months
- Selection criteria e.g. AI maturity, common good
- Publication of results

Collaborations

- Organised community meetings



Previous AI Pilot Projects

- Generation of maths problems
- Generation of plain language
- Generation of upcycling suggestions
- Reduction of food waste
- Dating of handwriting



[Apply now!](#)

Gefördert durch:



Bundesministerium
für Forschung, Technologie
und Raumfahrt

PILOT PROJECT: RAG SYSTEM

Readme ↻ G

Wie müssen Passwörter bei der Authentisierung am Webserver gesichert werden?

Used rag_retrieve ▾

APP.3.2.A5 Authentisierung (B) MUSS Passwörter kryptografisch gesichert und vor unbefugtem Zugriff geschützt gespeichert werden. **Quelle 1: APP.3.2.A5 Authentisierung (B) (S.397)**

APP.3.1.A14 Schutz vertraulicher Daten (B) MUSS Salted-Hash-Verfahren eingesetzt werden, damit Zugangsdaten zur Webanwendung serverseitig mit sicheren kryptografischen Algorithmen geschützt sind. **Quelle 2: APP.3.1.A1 Authentisierung (B) (S.391)**

Bezug zu Ihren Interessen:
Die Vorgaben decken exakt Ihre Schwerpunkte „Passwort-Hash-Verwaltung“ und „Webserver-Authentisierung“ ab: Passwörter werden per Salted-Hash kryptografisch geschützt, was den gängigen Best Practices Ihrer Arbeit entspricht.

📄 👍 🔖

Quellen anzeigen

Welche Verfahren zur Verwaltung von Salt-Werten empfehlen Sie im Rahmen des IT-Grundschutzes?

Wie können Sie die Einhaltung der Vorgaben zur Webserver-Passwortspeicherung in einem bestehenden System sicherstellen?

Type your message here...

📎 ⚙️ ↗

LLMs can make mistakes. Check important info.

← CITATIONS_PANEL

Quellen & Belegstellen

Quelle 1: APP.3.2.A5 Authentisierung (B) (S.397)

- Datei: `IT_Grundschutz_Kompendium_Edition2023.pdf`
- PDF: [Öffnen](#)
- Quellen-ID: 1
- Seiten: S.397
- Abschnitt: APP.3.2.A5 Authentisierung (B)
- Belegsnippet: "APP.3.2.A5 Authentisierung (B) Wenn sich Clients mit Hilfe von Passwörtern am Webserver authentisieren, MÜSSEN diese kryptografisch gesichert und vor unbefugtem Zugriff geschützt gespeichert werden."

Quelle 2: APP.3.1.A1 Authentisierung (B) (S.391)


- Datei: `IT_Grundschutz_Kompendium_Edition2023.pdf`
- PDF: [Öffnen](#)
- Quellen-ID: 2
- Seiten: S.391
- Abschnitt: APP.3.1.A1 Authentisierung (B)
- Belegsnippet: "APP.3.1.A1 Authentisierung (B) Der IT-

Gefördert durch:


Bundesministerium
für Forschung, Technologie
und Raumfahrt

PILOT PROJECT: OPEN RIVER SENSE

Training dataset: 3,056 European basins



River flow prediction at an ungauged location using weather forecasts
Basin GRDC_6338161 (52.68°N, 7.61°E)



Gefördert durch:



Bundesministerium
für Forschung, Technologie
und Raumfahrt

PILOT PROJECT: AUTOMATIC TRANSCRIPTION

Protokollierungsassistent

✓

2

3

HochladenZuordnenExportieren

Anleitung: 1) TOP links auswählen → 2) Zeilen rechts anklicken (Shift+Klick für Bereich) → 3) Zugeordnete Zeilen werden farblich markiert → Doppelklick auf Zeile zum Abspielen

Sprecher umbenennen (optional)

11 von 11 Zeilen zugeordnet

Tagesordnung

1. Feststellung der ordnungsg...
1 Zeilen

2. Bestätigung der Tagesordnu...
8 Zeilen

3. Bestätigung der Niederschri...
2 Zeilen

◀▶⏮⏭⏯⏸0:00 / 10:001x

Transkript

SPEAKER_04: So, meine sehr geehrten Damen und Herren, einen wunderschönen guten Abend in die Runde. Für mich ist heute die erste Sitzung nach der Sommerpause. Der eine oder andere hatte schon eine Sitzung vielleicht gehabt. Aber dann wollen wir wieder starten, gemeinsam starten. Wie ich hier soeben vor ein paar Minuten erfahren habe, bin ich heute berechtigt und in der Pflicht, die Versammlungsleitung wieder zu übernehmen, war, ehrlich gesagt, moralisch nicht so richtig emotional, nicht so richtig darauf vorbereitet, weil ich keine Informationen dazu hatte. Nichts dazu trotz, glaube ich, dass wir diese paar Punkte hier heute gut über die Bühne bekommen. Da kommt noch ein weiterer Teilnehmer, dann dürften wir 12. Möchte ich in die Tagesordnung einsteigen, die Ihnen ja hoffentlich allen zugegangen ist und zuerst die Beschlussfähigkeit feststellen. Wir sind zwölf Stimmberechtigte von 15 Abgeordneten hier in heute anwesend. Was ich von meiner Seite her etwas bemängeln muss gleich, dass ich eigentlich gar keine Vergabeunterlagen in dem Sinne bekommen habe, die heute hier aufgerufen sind. Aber da hoffe ich, dass aus der Verwaltung eine Aufklärung erfolgt. Gibt es Anmerkungen zur Tagesordnung von Ihrer Seite? Bitte. (1:26)

SPEAKER_03: Herr Schapke hat es ja schon richtig gesagt. Unsere Fraktion hat es ja auch schon mehrfach bemängelt. Wie sollen wir uns auf dem Ausschuss vorbereiten, wo wir nicht mal aussagekräftige Unterlagen haben, um auch gezielt Nachfragen zu bestimmten Themen zu haben? Also ich sehe mich heute nicht in der Lage, in der Kürze der Zeit vielleicht eine komplexe Vergabe zuzustimmen oder abzulehnen. (3:29)

SPEAKER_04: Ja, ich würde vielleicht schon mal, bevor wir hier zur, würde ich eine Stellungnahme abgeben. Bitte. (3:57)

SPEAKER_01: Also weil wir ja noch unter der Tagesordnung sind, will ich das jetzt gar nicht so weit ausführen, aber ich habe ja tatsächlich auch meine Rechtsauffassung dazu immer kundgetan und auch eigentlich immer beibehalten, nämlich diejenige, dass im Vorfeld die Übersendung von Vergabeunterlagen mit vertraulichen Informationen, also insbesondere

— Zurück

Zusammenfassungen erstellen →

Gefördert durch:



Bundesministerium
für Forschung, Technologie
und Raumfahrt

PILOT PROJECT: GENERATIVE AI



huggingface.co/datasets/aihpi/fashion-prompt-to-prompt



A cropped jacket with patch pockets, featuring bold tribal prints and tassel closures.

Original Caption



Add a detachable faux fur collar to the neckline for winter wear.

Edit Instruction



A cropped jacket with patch pockets, featuring bold tribal prints and tassel closures, now includes a detachable faux fur collar at the neckline.

Resulting Caption

DEMONSTRATOR: VOICE CLONING



<https://tts.aisc.hpi.de/>
user: event
pw: aisc@hpi2022!

Voice Dubbing Demonstrator

Runtime: Remote API | URL: <http://f5tts-api.f5-tts.svc.cluster.local:8004>

1 Record 2 Process 3 Scenario 4 Playback

Select Reference Audio

Consent notice: This demo processes biometric voice data. Use only your own voice or audio you are explicitly allowed to use.

☒ I confirm that I am allowed to use this voice sample for this demo.

Choose input method:

- ☒ Record Audio
☐ Use Predefined Audio

Click below to start/stop recording.



Next blocked: Please record or select a reference audio.

Process →

Voice Dubbing Demonstrator

Runtime: Remote API | URL: <http://f5tts-api.f5-tts.svc.cluster.local:8004>

1 Record 2 Process 3 Scenario 4 Playback

Police Call at Alexanderplatz

Cloned Voice (1/3)

Hey, ich bin's. Ich rufe aus der Polizeiwache am Alexanderplatz an, weil sie mich nach mehrfachem Schwarzfahren mitgenommen haben.



Gefördert durch:



Bundesministerium
für Forschung, Technologie
und Raumfahrt

DEMONSTRATOR: VISIONARY GESTURES



[https://vadimitri.github.io/
visionarygestures/](https://vadimitri.github.io/visionarygestures/)



Choose your Gamemode:

Rock Paper Scissors



The standard Rock Paper Scissors Game.

Play

Rock Paper Scissors + Lizard Spock




A Variation with two more moves: The
Lizard and Spock.

Play

Show your move now!

1



Gefördert durch:



Bundesministerium
für Forschung, Technologie
und Raumfahrt

DEMONSTRATOR: SKETCH2IMAGE



<https://s2i.aisc.hpi.de/>
user: aisctester
pw: 9OzJ5TzJZybVjm

sketch to image

AI MODEL

SD 1.5 + CONTROLNET SCRIBBLE
simple sketches | fast generation

SDXL + T2I-ADAPTER SKETCH
detailed sketches | high quality output

FLUX.1-CANNY-DEV
high-quality sketches | premium output
complex scenes

STYLE

photorealistic | anime
oil painting | watercolor
detailed sketch

DESCRIPTION

a tiny house and some trees in front of mountains and the sun

GENERATE IMAGE

RESET ALL

KI Service Zentrum HPI
powered by HPI's AI SERVICE CENTER

canvas

result

download | view full size

Gefördert durch:



Bundesministerium
für Forschung, Technologie
und Raumfahrt

CONTACT US



hpi.de/kisz



HPI

Email:
kisz@hpi.de

Das KI-Servicezentrum Berlin-Brandenburg ist ein Projekt am Hasso-Plattner-Institut. Wir fördern den Einsatz von Künstlicher Intelligenz in Wirtschaft und Gesellschaft.

Wir bieten Beratung, Weiterbildung und Infrastruktur, um KI-Anwendungen eigenständig zu entwickeln, zu betreiben und erfolgreich einzusetzen. Alle unsere Angebote sind kostenlos.

Unsere Angebote:

1. [Beratung](#)
2. [Weiterbildung](#)
3. [Infrastruktur](#)

Gefördert durch:



Bundesministerium
für Forschung, Technologie
und Raumfahrt

Virtueller Showroom

Wenn Sie KI eigenständig einsetzen möchten, benötigen Sie Zugang zu Modellen, Codes, Datensätzen und Expertise. All dies bieten wir Ihnen mit den Ergebnissen unserer Forschungs- und Projektarbeit in unserem virtuellen Showroom.

ZUM SHOWROOM ● ● ●

kisz@hpi.de
hpi.de/kisz

**Your
feedback is
important!**



QR-Code for feedback
questionnaire

