

Effizientes Abfragen von Informationen / Reinforcement Learning auf Basis Menschlichen Feedbacks

Lokales Retrieval Augmented-Generation System


David Goll und Jill Barvencik

**Design IT.
Create Knowledge.**

www.hpi.de



Anwesenheitsliste



Gefördert durch:



<https://hpi.de/ki-servicezentrum/>

Überblick

Gefördert durch:



Bundesministerium
für Forschung, Technologie
und Raumfahrt

Vier AI Service-Zentren in Deutschland



KI-Servicezentren

Ziel:

Reduktion von Barrieren bei der
Implementierung von KI-Anwendungen
in Gesellschaft und Wirtschaft.

KI-Servicezentrum Berlin Brandenburg

Struktur



Gefördert durch:



Bundesministerium
für Forschung, Technologie
und Raumfahrt

- KI-Methodenforschung
- KI-Betriebsforschung

Forschung

Gefördert durch:

PubMedCLIP: How Much Does CLIP Benefit Visual Question Answering in the Medical Domain?

Sedigheh Eslami, Christoph Meinel, Gerard de Melo
Hasso Plattner Institute / University of Potsdam
{sedigheh.eslami, christoph.meinel, gerard.demelo}@hpi.de

Abstract

Contrastive Language-Image Pre-training (CLIP) has shown remarkable success in learning with cross-modal supervision from extensive amounts of image-text pairs collected online. Thus far, the effectiveness of CLIP has been investigated primarily in general-domain multimodal problems. In this work, we evaluate the effectiveness of CLIP for the task of Medical Visual Question Answering (MedVQA). We present PubMedCLIP, a fine-tuned version of CLIP for the medical domain based on PubMed articles. Our experiments conducted on two MedVQA benchmark datasets illustrate that PubMedCLIP achieves superior results improving the overall accuracy up to 3% in comparison to the state-of-the-art Model-Agnostic Meta-Learning (MAML) networks pre-trained only on visual data. The PubMedCLIP model with different back-ends, the source code for pre-training them and reproducing our MedVQA pipeline is publicly available at <https://github.com/sarhESL/PubMedCLIP>.

1 Introduction

Medical visual question answering (MedVQA) seeks answers to natural language questions about a given medical image. The development of MedVQA has considerable potential to benefit health care systems, as it may aid clinicians in interpreting medical images and obtaining more accurate diagnoses by consulting a second opinion. Thus, it has become a very active area of research, with competitive benchmarks and yearly competitions (Abacha et al., 2021). Yet, visual question answering in the medical domain in particular remains non-trivial as we suffer from a general lack of large balanced training data, in part due to privacy concerns. To solve the multimodal task of MedVQA, a system must understand both medical images and textual questions and infer the associations between them sufficiently well to produce a correct answer (An

Findings of the Association for Computational Linguistics
May 2-6, 2023 ©2023 Association for Computational Linguistics

Exploring Paracrawl for Document-level Neural Machine Translation

Yusser Al Ghussin^{1,2}, Jingyi Zhang¹ and Josef van Genabith^{1,2}
¹German Research Center for Artificial Intelligence (DFKI),
Saarland Informatics Campus, Saarbrücken, Germany
²Department of Language Science and Technology, Saarland University, Germany
³Hasso-Plattner-Institut (HPI), Potsdam, Germany
yusser.al_ghussin@Josef.Van_Genabith@dfki.de, Jingyi.Zhang@hpi.de

Abstract

Document-level neural machine translation (NMT) has outperformed sentence-level NMT on a number of datasets. However, document-level NMT is still not widely adopted in real-world translation systems mainly due to the lack of large-scale general-domain training data for document-level NMT. We examine the effectiveness of using Paracrawl for learning document-level translation. Paracrawl is a large-scale parallel corpus crawled from the Internet and contains data from various domains. The official Paracrawl corpus was released as parallel sentences (extracted from parallel webpages) and therefore previous works only used Paracrawl for learning sentence-level translation. In this work, we extract parallel paragraphs from Paracrawl parallel webpages using automatic sentence alignments and we use the extracted parallel paragraphs as parallel documents for training document-level translation models. We show that document-level NMT models trained with only parallel paragraphs from Paracrawl can be used to translate real documents from TED, News and Europarl, outperforming sentence-level NMT models. We also perform a targeted pronoun evaluation and show that document-level models trained with Paracrawl data can help context-aware pronoun translation. We release our data and code here¹.

1 Introduction

The Transformer translation model (Vaswani et al., 2017), which performs sentence-level translation based on attention networks, has achieved great success and significantly improved the state-of-the-art in machine translation. Compared to sentence-level translation, document-level translation (Xu et al., 2021; Bao et al., 2021; Janney-Umanee et al., 2020; Ma et al., 2020; Maruf et al., 2019; Yu et al., 2018; Maruf and Haffari, 2018) performs translation at document-level and can potentially fur-

¹<https://github.com/Yusser96/Exploring-Paracrawl-for-Document-level-Neural-Machine-Translation>

Proceedings of the 17th Conference of the European Chapter of the Association for Computational Linguistics
May 2-6, 2023 ©2023 Association for Computational Linguistics

Efficient Parallelization Layouts for Large-Scale Distributed Model Training

Johannes Hagemann
Aleph Alpha / Hasso Plattner Institute
johannes.hagemann@student.hpi.de
Samuel Weinbach
Aleph Alpha
samuel.weinbach@aleph-alpha.com
Konstantin Dobler
Hasso Plattner Institute
konstantin.dobler@hpi.de
Maximilian Schall
Hasso Plattner Institute
maximilian.schall@hpi.de
Gerard de Melo
Hasso Plattner Institute
gerard.demelo@hpi.de

Abstract

Efficiently training large language models requires parallelizing across hundreds of hardware accelerators and invoking various compute and memory optimizations. When combined, many of these strategies have complex interactions regarding the final training efficiency. Prior work tackling this problem did not have access to the latest set of optimizations, such as FLASHATTENTION or sequence parallelism. In this work, we conduct a comprehensive ablation study of possible training configurations for large language models. We distill this large study into several key recommendations for the most efficient training. For instance, we find that using a micro-batch size of 1 usually enables the most efficient training layouts. Larger micro-batch sizes necessitate activation checkpointing or higher degrees of model parallelism and also lead to larger pipeline bubbles. Our most efficient configurations enable us to achieve state-of-the-art training efficiency results over a range of model sizes, most notably a Model FLOPs utilization of 70.5% when training a LLaMA 13B model.

1 Introduction

The number of parameters and computational resources spent on training deep neural networks is growing rapidly [1, 3, 14]. The largest models consisting of hundreds of billions of parameters do not even fit onto a single hardware accelerator. Thus, training these models requires various ways of reducing the memory requirements, such as ZeRO [16], activation checkpointing [2], and 3D-parallel (data, tensor, and pipeline parallel) training [13]. 3D parallelism, in particular, has been demonstrated to be effective for the training of Transformer-based large language models (LLMs) with hundreds of billions of parameters [13].

However, training these models efficiently with 3D parallelism requires significant domain expertise and extensive manual effort to determine the ideal configurations. These configurations not only need to combine data, model, and pipeline parallelism most efficiently, but also consider complex interactions with other memory and compute optimizations. FLASHATTENTION [5] in particular has had a notable impact since its release, enabling us to train models at previously impossible degrees of training efficiency. In light of these developments, we conduct a systematic study via a large-scale training efficiency sweep of these interactions. We consider up to 256 GPUs and LLaMA models with up to 65 billion parameters.

Workshop on Advancing Neural Network Training at 37th Conference on Neural Information Processing Systems (WANT@NeurIPS 2023).



Zugangsanfrage
aisc.hpi.de

Infrastruktur

Gefördert durch:



Bundesministerium
für Forschung, Technologie
und Raumfahrt



- **Kostenloser Zugang**
- Kein Produktionsbetrieb
 - Daten sollten **anonymisiert** oder **synthetisiert** werden
 - Kein **hosting** von Produkten
- **Berichterstattung & Veröffentlichung** durch Nutzer:innen
- **Alte Rechte** verbleiben bei Nutzer:innen
- **Neue Rechte** verbleiben bei Nutzer:innen
 - Gewährung von Nutzungsrechten für Forschung und Lehre

Training

- 64 NVIDIA H100 GPU

Inferenz

- 40 NVIDIA A30 GPU

ARM Server

- Ampere Altra Max M128-30 CPU
- 2 x NVIDIA L40 GPUs

GPU Server

- AMD Epyc CPU
- 8 x NVIDIA L40S GPU

Edge

- ARMv8 CPU
- NVIDIA Jetson AGX Module

Neuromorph

- 288 SpiNNaker2 Chips

Storage

- 1.5 PB NVMe

Network

- 400 Gb/s Infiniband
- 200 Gb/s Ethernet



Newsletter

Bildung

Talks



tele-task.de/series/1463

- Gastvorträge über Forschung und Innovation



Workshops



aimaker.community

- Praktische Themen
- Beispielthemen: Speech2summary, Docker für ML, Semantische Suche



MOOCs



open.hpi.de/channels/ai-service-center

- ChatGPT: Was bedeutet generative KI für die Gesellschaft?
- Profitable AI
- KI Biases verstehen und vermeiden



Gefördert durch:



Bundesministerium
für Forschung, Technologie
und Raumfahrt



Sprechstunde buchen

Consulting

AI consultation hours


- Answering questions:
 - about AI infrastructure
 - about AI models & frameworks
 - about AI use cases

AI pilot projects

- Co-development of a prototype
- Application every three months
- Selection criteria, e.g. AI maturity, public benefit
- Publication of results

Cooperation

- Jointly organized network meetings



Previous AI pilot projects

- Generation of math problems
- Generation of easy language
- Generation of upcycling suggestions
- Reduction of food waste
- Dating by handwriting



Jetzt bewerben!

Kontrast: Normal Kontrast: Invertiert Kontrast: Graustufen

KI-Prototyp Leichte-Sprache-Assistent (LeISA)

Vereinfache Texte mit LLMs! - [Zum Projekt auf GitHub](#)

Originaltext

Das KI-Servicezentrum Berlin-Brandenburg ist ein Projekt vom Hasso-Plattner-Institut. Unser Ziel ist, den Einsatz von Künstlicher Intelligenz in Wirtschaft und Gesellschaft zu fördern.

Unser Schwerpunkt liegt auf der Unterstützung von Start-ups, kleinen und mittelständischen Unternehmen, öffentlichen Einrichtungen, Studierenden und der Forschung. Wir bieten kostenfrei die notwendigen Beratungsleistungen, Bildungsangebote und Infrastruktur, um KI-Anwendungen zu entwickeln, zu betreiben und erfolgreich einzusetzen.

Leichte Sprache

Unser Ziel
Wir möchten, dass viele Menschen und Unternehmen KI-Anwendungen nutzen können.

Wer kann sich an uns wenden?
Studierende
Kleine und mittelständische Unternehmen
Start-ups
Öffentliche Einrichtungen

Was bieten wir an?
• Kostenlose Beratung
• Bildungsangebote
• Infrastruktur, um KI-Anwendungen zu entwickeln

Beispiele für unsere Arbeit
Ein Unternehmen möchte eine App entwickeln, die Menschen bei der Einkaufsliste hilft.
Eine Forschungsgruppe möchte ein System bauen, das Menschen bei der Krankenvorsorge unterstützt.
Wir helfen ihnen gerne!

Hinweis zur Übersetzung: Dieser Text wurde mit einer KI erstellt.
Bitte verarbeiten Sie keine personenbezogenen Daten mit dem Tool. Falls der Prototyp einmal nicht verfügbar sein sollte, kontaktieren Sie uns gern, wir kümmern uns darum.

Vereinfachen! Löschen

Der KI-Prototyp LeISA ist ein gemeinsames Projekt der DigitalAgentur Brandenburg GmbH und des KI-Servicezentrums (KSZ) vom Hasso-Plattner-Institut.
*Fördert durch das Ministerium der Justiz und für Digitalisierung des Landes Brandenburg
*Fördert vom Bundesministerium für Bildung und Forschung

github.com/aihpi/leichte-sprache



Gefördert durch:



Bundesministerium
für Forschung, Technologie
und Raumfahrt

Other Workshops

Reinforcement Learning Workshop Series



Gefördert durch:

RL I - Introduction

RL II - Application



LEARNING GOALS

Gefördert durch:



Bundesministerium
für Forschung, Technologie
und Raumfahrt

Motivation

- „Unser Chatbot gibt falsche oder unklare Antworten“
- „Wir wissen nicht, ob unser RAG-System zuverlässig ist“
- „Antworten sind nicht konsistent oder nicht hilfreich“
- „Die Evaluierung unseres RAG-Systems dauert zu lange“

Gefördert durch:

Lernziele

- RAG-Systeme systematisch bewerten und iterativ optimieren
- Verstehen, wie die Antwortqualität verbessert werden kann und wie „Qualität“ gemessen werden kann

Gefördert durch:

Agenda

1. Grundlagen Evaluation & Ausrichtung eines RAG-Systems

- RLHF, RLAIF
- RAGAS Metriken

2. Praxis und Diskussion

- RAGAS Metriken in Notebooks implementieren
- Auswertung und Anpassung des RAG-Systems

3. Ausblick auf RAG IV

Gefördert durch:




FUNDAMENTALS

Gefördert durch:




Bundesministerium
für Forschung, Technologie
und Raumfahrt

Kontext LLM



Kontext RAG



Evaluation und Ausrichtung eines RAG Systems

- Werden die richtigen Dokumente gefunden oder fehlen wichtige Informationen?
- Ist die Antwort durch den Kontext gedeckt oder halluziniert sie?
- Liegt das Problem am Retrieval oder am Modell?
- Wo genau ist mein RAG-System kaputt?

Evaluation

-
- Wie verhindere ich unerwünschte oder schlechte Antworten?
 - Wie evaluiert und optimiert man ein Modell in Bereichen, in denen es keine eindeutigen Erfolgsmetriken gibt?

Ausrichtung


GEFÖRDERT VOM

RLHF & RLAIIF – Überblick



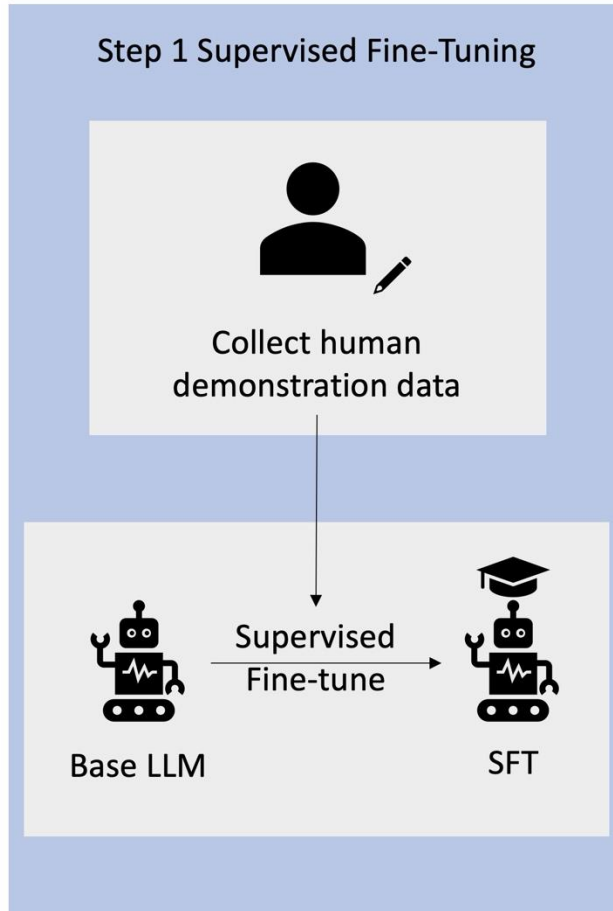
RLHF = Reinforcement Learning with human feedback

RLAIIF = Reinforcement Learning with AI feedback

- Was: Methode zur **Ausrichtung** von Modellverhalten
- Ziel: Bessere Antworten erzeugen, an menschliche Präferenzen anpassen, unerwünschtes Verhalten reduzieren
- Zuordnung: Teil des Trainings eines LLMs



RLHF und RLAIIF – Funktionsweise



GEFÖRDERT VOM

RLHF & RLAIIF – Einordnung

Aspekt	RLHF	RLAIIF
Feedback	Bewertung durch den Menschen	Bewertung durch LLM (AI as a judge)
Qualität	Sehr hoch, nah an menschlichen Präferenzen	Abhängig von Qualität & Prompt des Judge
Skalierbarkeit	Begrenzt durch menschliche Bewertung	Gut skalierbar durch Automatisierung
Kosten	Hoch durch Zeit & Aufwand von bewertenden Menschen	Hoch durch Computing Ressourcen aber besser skalierbar
Bias	Menschliche Vorurteile	Bias des Judge-Modells
Einsatz	Hochwertige, kritische Alignment-Daten	Große Datenmengen & automatisiertes Training
Optimierungs- verfahren	PPO, DPO	PPO, DPO

Evaluation und Ausrichtung eines RAG Systems

- Werden die richtigen Dokumente gefunden oder fehlen wichtige Informationen?
- Ist die Antwort durch den Kontext gedeckt oder halluziniert sie?
- Liegt das Problem am Retrieval oder am Modell?
- Wo genau ist mein RAG-System kaputt?

Evaluation

-
- Wie verhindere ich unerwünschte oder schlechte Antworten?
 - Wie evaluiert und optimiert man ein Modell in Bereichen, in denen es keine eindeutigen Erfolgsmetriken gibt?

Ausrichtung

GEFÖRDERT VOM

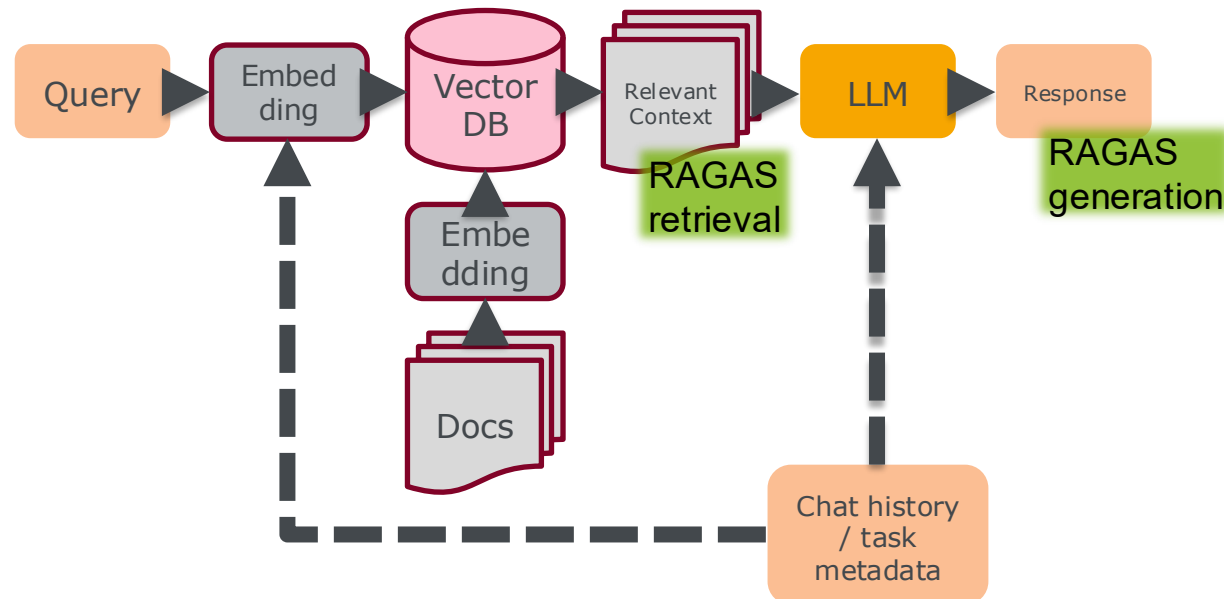
RAGAS – Überblick

RAGAS = Retrieval Augmented Generation Assessment Suite

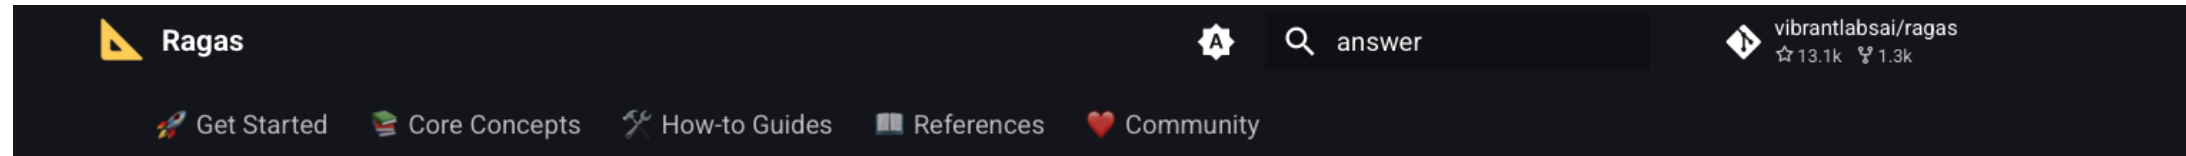
- Was: Framework zur **Evaluation** von RAG-Systemen, Nutzt Metriken und LLMs als Evaluator

- Ziel: Hilft Fehler im System zu lokalisieren

- Zuordnung:



RAGAS – Überblick



Introduction

 Copy page

Ragas is a library that helps you move from "vibe checks" to systematic evaluation loops for your AI applications. It provides tools to supercharge the evaluation of Large Language Model (LLM) applications, enabling you to evaluate your LLM applications with ease and confidence.

Why Ragas?

Traditional evaluation metrics don't capture what matters for LLM applications. Manual evaluation doesn't scale. Ragas solves this by combining **LLM-driven metrics** with **systematic experimentation** to create a continuous improvement loop.

<https://docs.ragas.io>

Table of contents

Why Ragas?

Key Features

Want help improving your AI application using evals?

GEFÖRDERT VOM



EXERCISE

Notebook 01

Gefördert durch:



Bundesministerium
für Forschung, Technologie
und Raumfahrt

Setup Instructions

Already have the repository from RAG II workshop installed?

NO

Start fresh

```
git clone https://github.com/aihpi/workshop-ragV2.git  
cd workshop-ragV2
```

YES

Option A — I don't need my old changes

```
git fetch origin  
git reset --hard origin/main
```

Option B — I want to keep my old changes

```
git checkout -b my-workshop2-changes  
git add -A && git commit -m "My workshop 2 work"  
git checkout main  
git fetch origin  
git reset --hard origin/main
```

Step 2: Install dependencies

```
scripts/setup_notebooks_kernel.sh
```

Step 3: Open notebooks/00_setup.ipynb

Select kernel Python (workshop-ragV2) and run all cells.
Enter the provided API key (valid until 08.04.26):

```
sk-UKXFOGt1nz_IYNcd52IWnw
```

Step 4: Have a break and wait for others to finish



GEFÖRDERT VOM



FUNDAMENTALS

Gefördert durch:



Bundesministerium
für Forschung, Technologie
und Raumfahrt

RAGAS – Context Precision – Retrieval Metrik

- Die Metrik kennzeichnet die **Fähigkeit, relevante Textabschnitte** im Ergebniskontext einer bestimmten Suchanfrage **höher zu ordnen** als irrelevante

$$\text{Context Precision @K} = \frac{\sum_{k=1}^K (\text{Precision @k} \times v_k)}{\text{Anzahl relevanter Kontexte in Top K}}$$

Wie gut sind die relevanten
Treffer im Ranking platziert

$$\text{Precision @k} = \frac{\text{Anzahl relevanter Kontexte @k}}{\text{Anzahl gefundener Kontexte @k}}$$

Anteil **relevanter** Treffer

K ist die totale Anzahl an Kontexten und $v_k \in \{0,1\}$ ist ein Indikator ob der Kontext relevant ist (1=relevant, 0=irrelevant)

RAGAS – Context Precision – Beispiel

Ranking: 1 , 2 

Context Precision = $1/1 = 1$

- **Precision@1 = $1/1 = 1$**
- Precision@2 = $1/2 = 0,5$

Ranking: 1 , 2 

Context Precision = $0,5/1 = 0,5$

- Precision@1 = $0/1 = 0$
- **Precision@2 = $1/2 = 0,5$**

Wie gut sind die relevanten
Treffer im Ranking platziert

Anteil **relevanter** Treffer

nur relevante Treffer werden
berücksichtigt mit $v=1$

RAGAS – Context Recall – Retrieval Metrik

- Die Metrik kennzeichnet, **wie viele der relevanten Treffer gefunden wurden**

$$\text{Context Recall} = \frac{\text{Anzahl gefundener relevanter Kontexte}}{\text{Anzahl aller relevanten Kontexte}}$$

RAGAS – Context Recall – Beispiel

Frage:

„Welche Farben hat eine
Ampel?“

(3 relevante Infos: **Rot**,
Gelb, **Grün**)

Retrieval:

- „**Rot**“
- „**Gelb**“

Context Recall:

- Gefunden 2 relevante
- Insgesamt vorhanden 3

Context Recall = $\frac{2}{3} = 0,67$

Reales Beispiel

IT-Grundschutz-Kompodium (858 Seiten) des Bundesamts für Sicherheit in der Informationstechnik



Gesamtinhaltsverzeichnis

Gesamtinhaltsverzeichnis

Vorwort
Dankesworte
Inhaltsverzeichnis
Neues im IT-Grundschutz-Kompodium
IT-Grundschutz – Basis für Informationssicherheit
Schichtenmodell und Modellierung
Rollen
Glossar

Elementare Gefährdungen

- G 0.1 Feuer
- G 0.2 Ungünstige klimatische Bedingungen
- G 0.3 Wasser
- G 0.4 Verschmutzung, Staub, Korrosion
- G 0.5 Naturkatastrophen
- G 0.6 Katastrophen im Umfeld
- G 0.7 Großereignisse im Umfeld
- G 0.8 Ausfall oder Störung der Stromversorgung
- G 0.9 Ausfall oder Störung von Kommunikationsnetzen
- G 0.10 Ausfall oder Störung von Versorgungsnetzen
- G 0.11 Ausfall oder Störung von Dienstleistungsunternehmen
- G 0.12 Elektromagnetische Störstrahlung
- G 0.13 Abfangen kompromittierender Strahlung
- G 0.14 Ausspähen von Informationen (Spionage)
- G 0.15 Abhören
- G 0.16 Diebstahl von Geräten, Datenträgern oder Dokumenten
- G 0.17 Verlust von Geräten, Datenträgern oder Dokumenten
- G 0.18 Fehlplanung oder fehlende Anpassung
- G 0.19 Offenlegung schützenswerter Informationen
- G 0.20 Informationen oder Produkte aus unzuverlässiger Quelle
- G 0.21 Manipulation von Hard- oder Software
- G 0.22 Manipulation von Informationen
- G 0.23 Unbefugtes Eindringen in IT-Systeme
- G 0.24 Zerstörung von Geräten oder Datenträgern
- G 0.25 Ausfall von Geräten oder Systemen
- G 0.26 Fehlfunktion von Geräten oder Systemen
- G 0.27 Ressourcenmangel
- G 0.28 Software-Schwachstellen oder -Fehler
- G 0.29 Verstoß gegen Gesetze oder Regelungen
- G 0.30 Unberechtigte Nutzung oder Administration von Geräten und Systemen
- G 0.31 Fehlerhafte Nutzung oder Administration von Geräten und Systemen
- G 0.32 Missbrauch von Berechtigungen
- G 0.33 Personalausfall
- G 0.34 Anschlag
- G 0.35 Nötigung, Erpressung oder Korruption
- G 0.36 Identitätsdiebstahl
- G 0.37 Abstreiten von Handlungen
- G 0.38 Missbrauch personenbezogener Daten

IT-Grundschutz-Kompodium: Stand Februar 2023

1

Gesamtinhaltsverzeichnis

- G 0.39 Schadprogramme
- G 0.40 Verhinderung von Diensten (Denial of Service)
- G 0.41 Sabotage
- G 0.42 Social Engineering
- G 0.43 Einspielen von Nachrichten
- G 0.44 Unbefugtes Eindringen in Räumlichkeiten
- G 0.45 Datenverlust
- G 0.46 Integritätsverlust schützenswerter Informationen
- G 0.47 Schädliche Seiteneffekte IT-gestützter Angriffe

Prozess-Bausteine

- ISMS: Sicherheitsmanagement
- ISMS.1 Sicherheitsmanagement
- ORP: Organisation und Personal
- ORP.1 Organisation
 - ORP.2 Personal
 - ORP.3 Sensibilisierung und Schulung zur Informationssicherheit
 - ORP.4 Identitäts- und Berechtigungsmanagement
 - ORP.5 Compliance Management (Anforderungsmanagement)
- CON: Konzepte und Vorgehensweisen
- CON.1 Kryptokonzept
 - CON.2 Datenschutz
 - CON.3 Datensicherungskonzept
 - CON.6 Löschen und Vernichten
 - CON.7 Informationssicherheit auf Auslandsreisen
 - CON.8 Software-Entwicklung
 - CON.9 Informationsaustausch
 - CON.10 Entwicklung von Webanwendungen
 - CON.11.1 Geheimschutz VS-NUR FÜR DEN DIENSTGEBRAUCH (VS-NfD)

OPS: Betrieb

- OPS.1 Eigener Betrieb
- OPS.1.1 Kern-IT-Betrieb
 - OPS.1.1.1 Allgemeiner IT-Betrieb
 - OPS.1.1.2 Ordnungsgemäße IT-Administration
 - OPS.1.1.3 Patch- und Änderungsmanagement
 - OPS.1.1.4 Schutz vor Schadprogrammen
 - OPS.1.1.5 Protokollierung
 - OPS.1.1.6 Software-Tests und -Freigaben
 - OPS.1.1.7 Systemmanagement
 - OPS.1.2 Weiterführende Aufgaben
 - OPS.1.2.2 Archivierung
 - OPS.1.2.4 Telearbeit
 - OPS.1.2.5 Fernwartung
 - OPS.1.2.6 NTP-Zeitsynchronisation
- OPS.2 Betrieb von Dritten
- OPS.2.2 Cloud-Nutzung
- OPS.3 Betrieb für Dritte
- OPS.3.2 Anbieten von Outsourcing

2

IT-Grundschutz-Kompodium: Stand Februar 2023

...



EXERCISE



Notebook 02 & 03

Gefördert durch:




Bundesministerium
für Forschung, Technologie
und Raumfahrt


Experiment 1 - Change Embedding Model





Score Distributions
octen-embedding-8b | json_structured_sections | 43_komplex | eval=gpt-oss-120b




Score Distributions
minilm-embedding | json_structured_sections | 43_komplex | eval=gpt-oss-120b




Experiment 2 - Change Chunking Method







Score Distributions
octen-embedding-8b | json_structured_sections | 43_komplex | eval=gpt-oss-120b





Score Distributions
octen-embedding-8b | markdown_headers | 43_komplex | eval=gpt-oss-120b




Experiment 3 - Change Dataset




Experiment 4 - Change Evaluator LLM



Score Distributions
octen-embedding-8b | json_structured_sections | 43_complex | eval=gpt-oss-120b



Score Distributions
octen-embedding-8b | json_structured_sections | 43_complex | eval=llama-3-3-70b



Experiments – Takeaway message

1. Das **Embedding-Modell** hat den größten Einfluss auf die Qualität eures RAG-Systems.
Alles Weitere (Chunking, Generierung, Evaluation) baut darauf auf.
2. Wählt **Chunking-Methode** und **TOP_K** passend zu euren Dokumenten.
Das TOP_K-Experiment zeigt, wo der beste Trade-off zwischen Precision und Recall liegt.
3. Der **Testdatensatz** sollte das gewünschte Verhalten des RAG-Systems widerspiegeln.
Das ist in der Praxis der größte Arbeitsaufwand.
4. Die Qualität des **Evaluator-LLMs** entscheidet über die Aussagekraft der Metriken.

GEFÖRDERT VOM



FUNDAMENTALS

Gefördert durch:



Bundesministerium
für Forschung, Technologie
und Raumfahrt

RAGAS – Answer Correctness – Generation Metrik

- Die Metrik kennzeichnet, **inwiefern die Antwort inhaltlich Korrekt** und **semantisch ähnlich** zum Ground Truth ist

Misst, wie viele Aussagen der
Antwort inhaltlich korrekt sind, unter
der Berücksichtigung von fehlenden
oder falschen Aussagen

$$\text{Answer Correctness} = 0,75 \frac{|TP|}{|TP| + 0,5(|FP| + |FN|)} + 0,25 \text{ Semantic Similarity}$$

FP: Anzahl an Aussagen, die nur in der Antwort vorkommen

FN: Anzahl an Aussagen, die nur in der Ground Truth vorkommen

TP: Anzahl an Aussagen, die in der Antwort und in der Ground Truth vorkommen

GEFÖRDERT VOM

RAGAS – Answer Correctness – Beispiel

Frage:

„Welche Farben hat eine
Ampel?“

Antwort:

- „Rot, Gelb und Blau“

Ground Truth:

- „Rot, Gelb und Grün“

TP=2 (Rot, Gelb)

FP=1 (Blau)

FN=1 (Grün fehlt)

$$\text{Answer Correctness} = 0,75 \frac{2}{2 + 0,5(1 + 1)} + 0,25 \text{ Semantic Similarity}$$

Oft die Cosine Similarity der
Embeddings von Antwort und
Ground Truth

RAGAS – Faithfulness – Generation Metrik

- Die Metrik kennzeichnet, wie **faktisch konsistent** eine Antwort mit dem abgerufenen Kontext ist. Sie liegt zwischen 0 und 1, wobei höhere Werte eine bessere Übereinstimmung anzeigen.

$$\text{Faithfulness} = \frac{\text{Anzahl in der Antwort durch den Retrieval unterstützten Aussagen}}{\text{Anzahl aller Aussagen in der Antwort}}$$

RAGAS – Faithfulness – Beispiel

Frage:

„Welche Farben hat eine Ampel?“

Retrieval:

- „Eine Ampel hat die Farben Rot, Gelb und Grün“

Antwort:

- „Eine Ampel hat die Farbe Rot, Gelb und Blau“

Faithfulness = $\frac{2}{3} = 0,67$




EXERCISE

Notebook 04

Gefördert durch:



Bundesministerium
für Forschung, Technologie
und Raumfahrt



Gefördert durch:



Bundesministerium
für Forschung, Technologie
und Raumfahrt



DISCUSSION

Gefördert durch:



Bundesministerium
für Forschung, Technologie
und Raumfahrt

kisz@hpi.de

hpi.de/kisz

Deine Meinung
ist wichtig!



QR code zum Feedback
Formular



Gefördert durch: